

LAPORAN AKHIR

PERBANDINGAN ENHANCEMENT TRADISIONEL VS DEEP LEARNING PADA CITRA OBJEK RUMAH

*Disusun Untuk Memenuhi Tugas Kuliah
Mata Kuliah : Pengolahan Citra Digital*

Dosen pembimbing :
Muhammad Ikhwan Thohir, M.Kom



Disusun Oleh :

- Boyke Ramadha
- Muhammad Hafiz
- Rahmat Hidayat

Kelas : TI 23 H

PROGRAM S1 TEKNIK INFORMATIKA
FAKULTAS TEKNIK KOMPUTER
UNIVERSITAS NUSA PUTRA
TAHUN 2026

1. Pendahuluan

Pengolahan Citra Digital (PCD) merupakan salah satu cabang ilmu yang mempelajari bagaimana citra atau gambar dapat diproses menggunakan komputer untuk menghasilkan informasi tertentu. Dalam penerapannya, PCD banyak digunakan pada berbagai bidang seperti sistem keamanan (CCTV), pengenalan objek, kendaraan otonom, analisis medis, industri manufaktur, hingga sistem dokumentasi digital. Namun, keberhasilan suatu sistem pengolahan citra sangat bergantung pada kualitas citra input yang digunakan.

Pada kondisi nyata, citra yang diperoleh dari perangkat kamera (misalnya kamera HP) sering mengalami penurunan kualitas akibat berbagai faktor. Faktor tersebut dapat berupa pencahayaan yang kurang stabil, bayangan, kualitas sensor kamera, resolusi yang terbatas, gerakan saat pengambilan gambar, serta adanya gangguan noise. Noise dapat menyebabkan citra terlihat berbintik, detail objek menjadi tidak jelas, dan batas antara objek dengan latar belakang menjadi sulit dikenali. Hal ini akan berdampak pada tahapan berikutnya seperti segmentasi, deteksi tepi, ataupun ekstraksi fitur yang membutuhkan citra yang bersih dan jelas.

Salah satu solusi yang digunakan untuk mengatasi masalah tersebut adalah image enhancement atau peningkatan kualitas citra. Enhancement bertujuan untuk memperbaiki tampilan visual citra agar objek terlihat lebih jelas, kontras meningkat, dan gangguan noise dapat dikurangi. Pada umumnya terdapat dua pendekatan utama dalam enhancement, yaitu metode tradisional (konvensional) dan metode berbasis pembelajaran (learning-based/deep learning).

Metode tradisional biasanya memanfaatkan teknik berbasis filter dan manipulasi kontras yang telah dikenal luas dalam PCD. Pada project ini, metode tradisional yang digunakan adalah kombinasi Non-Local Denoising untuk reduksi noise dan CLAHE (Contrast Limited Adaptive Histogram Equalization) untuk peningkatan kontras secara adaptif. Metode ini memiliki kelebihan karena implementasinya sederhana, cepat, dan tidak memerlukan pelatihan model. Namun, pada beberapa kondisi tertentu enhancement tradisional dapat memperkuat tekstur background atau menghasilkan detail yang kurang natural.

Di sisi lain, metode learning-based atau deep learning berkembang pesat karena mampu mempelajari pola kompleks dari data. Pada project ini, pendekatan deep learning yang digunakan bukan CNN penuh, tetapi menggunakan konsep learning-based enhancement berbasis *patch extraction* dan pelatihan dengan *supervised regression (least squares)*. Model belajar dari pasangan input dan target untuk menghasilkan citra yang lebih baik. Pendekatan ini diharapkan mampu menghasilkan peningkatan citra yang lebih adaptif dibanding metode tradisional, karena model memiliki kemampuan menyesuaikan perbaikan berdasarkan data latih.

Untuk menguji efektivitas enhancement yang digunakan, project ini tidak hanya mengandalkan penilaian visual, tetapi juga melakukan pengujian pada tahapan lanjutan yaitu segmentasi citra menggunakan metode SLIC Superpixel. Segmentasi bertujuan untuk membagi citra menjadi beberapa region kecil sehingga objek dapat dipisahkan dari background. Kualitas segmentasi sangat dipengaruhi oleh kualitas citra input, sehingga hasil segmentasi dapat menjadi indikator kuat apakah enhancement berhasil memperjelas objek atau tidak.

Selanjutnya, hasil segmentasi dari metode tradisional dan learning-based dievaluasi menggunakan metrik kuantitatif yaitu Dice Score dan IoU (Intersection over Union). Dice dan IoU digunakan untuk mengukur tingkat kesamaan antara hasil prediksi segmentasi dan ground truth yang dibuat, sehingga perbandingan yang dilakukan tidak hanya bersifat subjektif tetapi juga didukung angka evaluasi.

Melalui eksperimen ini, dilakukan beberapa pengujian pada berbagai objek seperti kacamata, pensil warna, gelas, cincin, dan kartu tanda mahasiswa. Pengujian dilakukan dengan variasi sudut serta jarak pengambilan gambar agar hasil perbandingan lebih representatif terhadap kondisi nyata. Diharapkan hasil project ini dapat memberikan gambaran mengenai performa pendekatan enhancement tradisional dibandingkan learning-based, khususnya dalam mendukung segmentasi objek pada citra yang terdegradasi noise.

1.1. Tujuan

1. Mengimplementasikan proses penambahan noise dan peningkatan kualitas citra menggunakan metode tradisional dan learning-based.

2. Membandingkan hasil enhancement dari kedua metode secara visual dan kuantitatif.
3. Menguji dampak enhancement terhadap hasil segmentasi objek menggunakan metode SLIC Superpixel.
4. Mengukur kualitas segmentasi menggunakan Dice Score dan IoU untuk menentukan metode yang lebih baik.

1.2. Rumusan Masalah

1. Bagaimana hasil peningkatan citra menggunakan metode tradisional (Non-Local Denoising + CLAHE) pada citra yang diberi Gaussian noise?
2. Bagaimana hasil peningkatan citra menggunakan metode learning-based enhancement pada kondisi yang sama?
3. Metode mana yang memberikan hasil segmentasi lebih baik berdasarkan Dice Score dan IoU?

1.3. Manfaat

- Memberikan pemahaman penerapan enhancement citra untuk memperbaiki citra noisy.
- Menjadi referensi perbandingan antara metode tradisional dan learning-based pada pengolahan citra objek.
- Membantu mengetahui hubungan antara kualitas enhancement dengan kualitas segmentasi citra.
- Menjadi dasar pengembangan metode yang lebih lanjut seperti penggunaan CNN atau deep learning penuh pada penelitian selanjutnya.

2. Akuisisi Data

2.1. Dokumentasi Pengambilan Data Uji

Pengambilan data dilakukan menggunakan **kamera HP** dengan metode pengambilan gambar langsung pada objek yang diuji. Objek diletakkan di atas alas berwarna (biru) untuk membantu pemisahan objek dengan latar belakang saat proses segmentasi.

Pengambilan gambar dilakukan secara manual dengan beberapa variasi:

- Jarak dekat dan jarak sedang
- Sudut kamera depan dan miring
- Posisi objek tegak dan serong

Tujuan variasi ini adalah untuk menguji seberapa stabil metode enhancement pada kondisi nyata, di mana pencahayaan dan sudut pengambilan gambar tidak selalu sama.



Gambar 2.2 Dokumentasi Pengambilan Gambar Uji Menggunakan HP



Gambar 2.2 Dokumentasi Pengambilan Gambar Uji Menggunakan HP

Pada gambar tersebut terlihat proses pengambilan citra objek uji menggunakan kamera HP. Objek (contoh: kacamata) ditempatkan pada alas biru di atas permukaan datar dan difoto dari arah samping untuk memperoleh citra RGB sebagai input sistem.

3. Landasan Teori

3.1. Pengolahan Citra Digital

Pengolahan Citra Digital (PCD) adalah proses memanipulasi dan menganalisis citra menggunakan komputer untuk meningkatkan kualitas visual atau mengekstraksi informasi tertentu. Citra digital direpresentasikan dalam bentuk matriks piksel, dimana setiap piksel memiliki nilai intensitas yang menggambarkan warna atau tingkat kecerahan. Dalam project ini, citra diproses dalam format RGB, sehingga setiap piksel memiliki tiga kanal yaitu Red (R), Green (G), dan Blue (B).

3.2. Noise Pada Citra Digital

Noise adalah gangguan acak yang menyebabkan kualitas citra menurun. Noise dapat muncul akibat faktor seperti pencahayaan rendah, sensor kamera, kompresi gambar, atau proses pengiriman data. Dampak noise pada citra antara lain membuat citra tampak berbintik, detail objek menjadi kabur, serta batas antara objek dan background sulit dikenali. Noise menjadi masalah utama karena dapat menurunkan performa proses lanjutan seperti segmentasi atau deteksi objek.

3.2.1. Gaussian Noise

Gaussian noise adalah noise yang mengikuti distribusi normal (Gaussian). Pada citra, noise ini menambahkan nilai acak ke intensitas piksel sehingga citra tampak “berpasir” atau bergranul. Dalam project ini, Gaussian noise digunakan untuk mensimulasikan kondisi citra yang terdegradasi sehingga dapat diuji apakah metode enhancement mampu mengembalikan kualitas citra.

3.3. Image Enhancement

Image enhancement adalah proses peningkatan kualitas citra agar informasi yang terkandung di dalam citra lebih mudah diamati atau diproses. Enhancement biasanya digunakan untuk:

- mengurangi noise,
- memperbaiki kontras,
- memperjelas struktur dan detail objek,
- memudahkan segmentasi atau analisis objek.

Pada project ini digunakan dua pendekatan enhancement, yaitu tradisional dan learning-based.

3.4. Enhancement Tradisional (Non-Local Denoising + CLAHE)

3.4.1. Non-Local Denoising

Non-Local Denoising merupakan teknik pereduksi noise yang bekerja dengan prinsip mencari kesamaan pola pada bagian lain citra, kemudian menggabungkan informasi tersebut untuk memperhalus noise tanpa menghilangkan detail penting. Teknik ini efektif untuk mengurangi noise sambil menjaga struktur objek agar tidak terlalu blur.

Kelebihan:

- mampu mengurangi noise dengan cukup baik,
- detail objek relatif tetap terjaga.

Kekurangan:

- memerlukan komputasi lebih besar dibanding filter sederhana,
- pada beberapa kondisi dapat menghasilkan citra terlihat terlalu halus.

3.4.2. CLAHE (Contrast Limited Adaptive Histogram Equalization)

CLAHE adalah metode peningkatan kontras yang bekerja secara lokal (per area kecil), berbeda dari histogram equalization biasa yang bekerja pada seluruh citra. CLAHE membatasi peningkatan kontras agar tidak membuat noise semakin terlihat. Hal ini penting karena citra noisy bisa semakin buruk jika kontras ditingkatkan tanpa batas.

Kelebihan:

- memperjelas detail dan tekstur objek,
- meningkatkan kontras lokal secara adaptif.

Kekurangan:

- jika parameter tidak tepat, noise pada background bisa ikut meningkat.

3.5. Enhancement Learning-based (Deep Learning Sederhana)

Enhancement learning-based adalah pendekatan peningkatan citra menggunakan konsep pembelajaran dari data. Pada project ini metode learning-based diterapkan dengan model sederhana berbasis supervised regression, yaitu model belajar hubungan antara citra noisy dengan citra target (enhanced reference).

Metode ini bekerja dengan cara:

1. Mengambil patch kecil dari citra noisy sebagai input.
2. Mengambil patch dari citra hasil enhancement tradisional sebagai target.

3. Melatih model agar mampu memprediksi patch yang telah ditingkatkan kualitasnya.

Pendekatan ini bersifat data-driven karena output yang dihasilkan mengikuti pola yang dipelajari dari data.

Kelebihan:

- lebih adaptif terhadap pola noise,
- hasil citra cenderung lebih stabil dan natural.

Kekurangan:

- membutuhkan pelatihan model,
- performa sangat dipengaruhi kualitas data latih dan target.

3.6. Patch Extraction dan Sliding Window

Patch extraction adalah teknik membagi citra menjadi potongan kecil berukuran tertentu (misalnya 7×7) untuk digunakan sebagai data latih. Patch digunakan agar model fokus mempelajari hubungan lokal antar piksel. Selanjutnya saat inferensi, patch diterapkan ke seluruh citra menggunakan sliding window, sehingga output citra enhancement dihasilkan secara bertahap dan digabungkan kembali.

Dalam project ini, penggabungan patch dilakukan menggunakan rata-rata (averaging) pada daerah overlap agar hasil akhir lebih halus dan mengurangi efek blok.

3.7. Segmentasi Citra

Segmentasi citra merupakan proses membagi citra menjadi beberapa bagian (region) untuk memisahkan objek dari latar belakang. Segmentasi penting karena menjadi tahap awal untuk analisis objek lebih lanjut seperti penghitungan bentuk, deteksi objek, atau klasifikasi.

Segmentasi yang baik biasanya menghasilkan:

- batas objek jelas,
- objek terpisah dari background,
- area objek tidak terputus-putus.

3.8. Segmentasi SLIC (Simple Linear Iterative Clustering)

SLIC merupakan metode segmentasi berbasis superpixel yang membagi citra menjadi beberapa region kecil berdasarkan kedekatan warna dan lokasi piksel. SLIC menghasilkan superpixel yang memudahkan analisis struktur objek. Dalam project ini, SLIC digunakan untuk melihat apakah enhancement membantu pemisahan objek dari background.

Kelebihan:

- menghasilkan pembagian region yang cukup rapi,
- cepat dan umum digunakan.

Kekurangan:

- sensitif terhadap noise dan perubahan warna pada background,
- jumlah superpixel dan parameter compactness sangat berpengaruh.

3.9. Ground Truth (GT)

Ground truth adalah acuan kebenaran yang digunakan untuk membandingkan hasil prediksi sistem. Dalam evaluasi segmentasi, ground truth berupa mask objek yang menunjukkan area objek sebenarnya. Dengan ground truth, hasil segmentasi bisa dinilai secara objektif menggunakan metrik evaluasi seperti Dice dan IoU.

3.10. Evaluasi Segmentasi (Dice Score dan IoU)

3.10.1. Intersection over Union (IoU)

IoU mengukur tingkat overlap antara hasil segmentasi prediksi dengan ground truth. Nilai IoU dihitung dari perbandingan area irisan terhadap area gabungan.

Interpretasi:

- IoU mendekati 1 → segmentasi sangat baik
- IoU mendekati 0 → segmentasi buruk

3.10.2. Dice Score

Dice Score menghitung kemiripan dua mask dengan memberikan bobot lebih pada area overlap. Dice sering digunakan pada segmentasi karena sensitif terhadap kesalahan kecil pada objek.

Interpretasi:

- Dice mendekati **1** → hasil segmentasi sangat sesuai GT
- Dice mendekati **0** → hasil segmentasi sangat berbeda

3.11. Hubungan Enhancement dan Segmentasi

Secara teori, enhancement yang baik akan:

- mengurangi noise,
- mempertajam batas objek,
- meningkatkan kontras objek terhadap background,

sehingga segmentasi menjadi lebih mudah dan nilai evaluasi (Dice & IoU) meningkat. Karena itu, dalam project ini enhancement dibandingkan bukan hanya dari visual, tetapi juga dari dampaknya terhadap kualitas segmentasi.

4. Metodologi

4.1. Alur Umum Sistem

Secara umum proses yang dilakukan dalam project ini adalah sebagai berikut:

1. Input citra RGB hasil akuisisi menggunakan kamera HP
2. Preprocessing awal (konversi format & penyesuaian data)
3. Penambahan Gaussian noise (simulasi citra terdegradasi)
4. Enhancement menggunakan metode tradisional
5. Enhancement menggunakan metode learning-based
6. Segmentasi citra menggunakan SLIC superpixel
7. Evaluasi hasil segmentasi menggunakan Dice dan IoU
8. Analisis perbandingan hasil kedua metode



Gambar 4.1 Flowchart Alur Proses Peningkatan Citra Objek

4.2. Dataset dan Sumber Data

Dataset pada penelitian ini berupa citra objek sehari-hari yang diambil menggunakan kamera HP. Setiap objek difoto dalam kondisi pencahayaan ruangan dan latar sederhana untuk memudahkan observasi hasil enhancement dan segmentasi.

Objek yang digunakan dalam pengujian meliputi:

- Kacamata
- Kotak pensil warna
- Gelas
- Cincin
- Kartu mahasiswa
- Tas

Tujuan penggunaan beberapa objek adalah untuk melihat kestabilan metode enhancement terhadap variasi tekstur, ukuran objek, dan kompleksitas background.

4.3. Tools dan Lingkungan Pengembangan

Project ini dikerjakan menggunakan beberapa tools berikut:

- Google Colab: sebagai platform utama implementasi program Python dan pemrosesan citra
- HP: digunakan untuk pengambilan citra objek (akuisisi data)
- ChatGPT: digunakan sebagai bantuan penyusunan laporan, penjelasan konsep, serta perapihan dokumentasi project

4.4. Tahap Preprocessing

```
SET UP ENVIRONMENT

import cv2
import numpy as np
import matplotlib.pyplot as plt

from skimage import restoration, filters, segmentation, metrics, morphology, color
from skimage.util import random_noise
from google.colab import files
%matplotlib inline
```

```

uploaded = files.upload()

# Ambil satu file gambar
image_path = list(uploaded.keys())[0]

# Load image (OpenCV default BGR + convert ke RGB)
img = cv2.imread(image_path)
img_rgb = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)

plt.figure(figsize=(6,6))
plt.imshow(img_rgb)
plt.title("Citra Rumah Asli (RGB)")
plt.axis("off")

```

Pada tahap preprocessing awal, citra hasil upload dibaca menggunakan OpenCV. Karena OpenCV secara default membaca citra dalam format BGR, maka dilakukan konversi menjadi RGB agar tampilan sesuai dengan standar visual.

Tahapan preprocessing:

1. Upload gambar ke Colab
2. Membaca citra menggunakan cv2.imread()
3. Konversi citra dari BGR ke RGB menggunakan cv2.cvtColor()

Tujuan preprocessing ini adalah memastikan citra dapat diproses dan divisualisasikan dengan benar sebelum diberi noise dan dilakukan enhancement.

4.5. Penambahan Noise Gaussian

```

# PENAMBAHAN GAUSSIAN NOISE

noisy_img = random_noise(img_rgb, mode='gaussian', var=0.01)
noisy_img = (noisy_img * 255).astype(np.uint8)

plt.figure(figsize=(5,5))
plt.imshow(noisy_img)
plt.title("Citra Rumah Terdegradasi (Noise RGB)")
plt.axis("off")

```

Untuk mensimulasikan kondisi citra yang rusak atau menurunkan kualitasnya, citra asli diberi noise Gaussian. Penambahan noise dilakukan agar dapat menguji performa enhancement tradisional dan learning-based dalam memperbaiki citra yang terdegradasi.

Proses ini menghasilkan dua citra utama:

- Citra Asli (input utama)
- Noisy Input (citra terdegradasi)

Tahap penambahan noise adalah bagian penting karena enhancement diuji berdasarkan kemampuan memulihkan citra noisy.

4.6. Enhancement Tradisional (Non-Local Denoising + CLAHE)

```

# DENOISING TRADITIONAL + CLAHE
denoise_trad = cv2.bilateralFilter(noisy_img, 9, 75, 75)

# CLAHE RGB
def clahe_rgb(img):
    clahe = cv2.createCLAHE(2.0, (8,8))
    channels = cv2.split(img)
    out = [clahe.apply(c) for c in channels]
    return cv2.merge(out)

enh_trad = clahe_rgb(denoise_trad)

plt.figure(figsize=(5,5))
plt.imshow(enh_trad)
plt.title("Enhancement Konvensional (Bilateral + CLAHE)")
plt.axis("off")

```

4.6.1 Non-Local Denoising

Tahap ini bertujuan mengurangi noise pada citra noisy dengan mempertahankan struktur objek. Non-local denoising bekerja dengan memanfaatkan kemiripan pola pada berbagai bagian citra sehingga hasil akhir tidak terlalu blur.

4.6.1.1 CLAHE

Setelah noise berkurang, dilakukan peningkatan kontras menggunakan CLAHE. CLAHE dipilih karena mampu meningkatkan kontras lokal tanpa memperkuat noise secara berlebihan, sehingga detail objek menjadi lebih jelas.

4.7. Enhancement Learning-based (Deep Learning Sederhana)

Metode learning-based pada project ini digunakan untuk menghasilkan enhancement berbasis pembelajaran. Model tidak menggunakan CNN penuh, namun menggunakan supervised learning sederhana berbasis regresi.

Tahap learning-based dibagi menjadi 3 bagian:

```

#PERSIAPAN DATA LATIH
# Parameter patch
PATCH_SIZE = 7
STRIDE = 3

def extract_patches(img, patch_size, stride):
    patches = []
    h, w, c = img.shape
    for y in range(0, h - patch_size, stride):
        for x in range(0, w - patch_size, stride):
            patch = img[y:y+patch_size, x:x+patch_size, :]
            patches.append(patch.flatten())
    return np.array(patches)

# Input training: noisy image
X_train = extract_patches(noisy_img, PATCH_SIZE, STRIDE)

# Target training: enhanced reference (CLAHE output sebagai proxy GT)
Y_train = extract_patches(enh_trad, PATCH_SIZE, STRIDE)

print("Training samples:", X_train.shape)



---


Training samples: (144075, 147)

#PELATIHAN MODEL
# Tambahkan bias
X_aug = np.hstack([X_train, np.ones((X_train.shape[0], 1))])

# Least Squares Training
W = np.linalg.lstsq(X_aug, Y_train, rcond=None)[0]

print("Model trained: Weight matrix shape =", W.shape)



---


Model trained: Weight matrix shape = (148, 147)

#INFERENSI ENHANCEMENT
def apply_learned_enhancement(img, W, patch_size):
    h, w, c = img.shape
    out = img.copy().astype(np.float32)
    count = np.zeros_like(out)

    for y in range(0, h - patch_size, 1):
        for x in range(0, w - patch_size, 1):
            patch = img[y:y+patch_size, x:x+patch_size, :].flatten()
            patch_aug = np.append(patch, 1)
            pred = patch_aug @ W
            pred = pred.reshape((patch_size, patch_size, 3))

            out[y:y+patch_size, x:x+patch_size, :] += pred
            count[y:y+patch_size, x:x+patch_size, :] += 1

    return np.clip(out / (count + 1e-8), 0, 255).astype(np.uint8)

enh_d1 = apply_learned_enhancement(noisy_img, W, PATCH_SIZE)

plt.figure(figsize=(5,5))
plt.imshow(enh_d1)
plt.title("Learned RGB Enhancement (Trained Model)")
plt.axis("off")

```

```

    # PERBANDINGAN TRADITIONAL VS DEEP LEARNING

    plt.figure(figsize=(16,4))

    plt.subplot(1,4,1)
    plt.imshow(img_rgb)
    plt.title("Citra Asli")
    plt.axis("off")

    plt.subplot(1,4,2)
    plt.imshow(noisy_img)
    plt.title("Noisy Input")
    plt.axis("off")

    plt.subplot(1,4,3)
    plt.imshow(enh_trad)
    plt.title("Konvensional")
    plt.axis("off")

    plt.subplot(1,4,4)
    plt.imshow(enh_dl)
    plt.title("Deep Learning Enhancement")
    plt.axis("off")

    plt.tight_layout()
    plt.show()

```

4.7.1. Persiapan Data Latih (Patch Extraction)

Citra dibagi menjadi patch berukuran kecil untuk membentuk pasangan data latih.

- Input (X): patch dari citra noisy
- Target (Y): patch dari citra referensi (hasil enhancement tradisional)

Pendekatan ini digunakan agar model belajar hubungan lokal antar piksel (patch-to-patch).

4.7.2. Pelatihan Model (Training)

Pelatihan dilakukan menggunakan supervised regression (least squares) untuk mendapatkan matriks bobot yang merepresentasikan transformasi dari noisy menjadi enhanced.

Tujuannya adalah membentuk model yang mampu memperbaiki citra noisy secara otomatis berdasarkan pola yang telah dipelajari.

4.7.3. Inferensi Enhancement (Prediction)

Setelah model terlatih, enhancement diterapkan pada citra noisy menggunakan teknik sliding window.

Karena patch saling overlap, dilakukan averaging agar:

- hasil citra lebih halus
- mengurangi efek blok antar patch

4.8. Segmentasi Menggunakan SLIC Superpixel

```

# Segmentasi sederhana sebagai ground truth pendekatan
gt = cv2.inRange(img_rgb, (100, 100, 100), (255, 255, 255))
gt = morphology.remove_small_objects(gt.astype(bool), min_size=500)
gt = gt.astype(np.uint8)

#SEGMENTASI OBJEK
# Gunakan slic superpixel
segments_trad = segmentation.slic(
    enh_traditional, n_segments=300, compactness=10, start_label=1
)

segments_dl = segmentation.slic(
    enh_dl, n_segments=300, compactness=10, start_label=1
)

fig, ax = plt.subplots(1,2, figsize=(12,6))

ax[0].imshow(segmentation.mark_boundaries(enh_traditional, segments_trad))
ax[0].set_title("Segmentasi (Tradisional)")
ax[0].axis("off")

ax[1].imshow(segmentation.mark_boundaries(enh_dl, segments_dl))
ax[1].set_title("Segmentasi (Learning-based)")
ax[1].axis("off")

```

Setelah enhancement selesai, citra hasil enhancement tradisional dan learning-based diproses menggunakan segmentasi SLIC.

Segmentasi dilakukan pada dua citra:

1. Citra hasil tradisional
2. Citra hasil learning-based

Output segmentasi ditampilkan dalam bentuk boundary/garis pembatas superpixel untuk melihat region objek dan background.

Tujuan utama segmentasi pada project ini adalah mengukur apakah enhancement membantu memisahkan objek dari latar belakang.

4.9. Evaluasi Menggunakan Dice Score dan IoU

```

## EVALUASI KUALITAS GAMBAR

def evaluate_segmentation(pred, gt):
    """
    pred, gt : binary mask (True/False atau 0/1)
    """
    pred = pred.astype(bool)
    gt = gt.astype(bool)

    intersection = np.logical_and(pred, gt).sum()
    union = np.logical_or(pred, gt).sum()

    dice = (2 * intersection) / (pred.sum() + gt.sum() + 1e-8)
    iou = intersection / (union + 1e-8)

    return dice, iou

## Ambil satu region dominan sebagai objek (pendekatan studi kasus)
seg_trad_binary = segments_trad == np.bincount(segments_trad.flatten()).argmax()
seg_dl_binary = segments_dl == np.bincount(segments_dl.flatten()).argmax()

dice_trad, iou_trad = evaluate_segmentation(seg_trad_binary, gt)
dice_dl, iou_dl = evaluate_segmentation(seg_dl_binary, gt)

print("== Evaluasi Segmentasi ==")
print(f"Tradisional + Dice: {dice_trad:.3f}, IoU: {iou_trad:.3f}")
print(f"Learning-based + Dice: {dice_dl:.3f}, IoU: {iou_dl:.3f}")

== Evaluasi Segmentasi ==
Tradisional + Dice: 0.052, IoU: 0.027
Learning-based + Dice: 0.129, IoU: 0.069

```

Untuk membandingkan performa segmentasi pada kedua metode enhancement, dilakukan evaluasi menggunakan Dice dan IoU.

Tahap evaluasi dilakukan dengan cara:

1. Membuat/mengambil **ground truth (GT)** berupa mask objek
2. Membandingkan hasil segmentasi prediksi dengan GT
3. Menghitung Dice dan IoU untuk metode tradisional dan learning-based

Semakin besar nilai Dice dan IoU, maka hasil segmentasi dianggap semakin akurat.

4.10. Skenario Pengujian

Pengujian dilakukan sebanyak **16 uji** dengan beberapa objek yang berbeda. Setiap uji menghasilkan output utama berupa:

- citra asli
- noisy input
- hasil enhancement tradisional
- hasil enhancement learning-based
- hasil segmentasi tradisional dan learning-based
- nilai Dice dan IoU

5. Implementasi dan Hasil

Bab ini membahas implementasi sistem yang telah dirancang pada Bab 4 serta menampilkan hasil pengujian enhancement dan segmentasi citra. Hasil yang ditampilkan mencakup perbandingan visual antara metode tradisional dan learning-based, serta nilai evaluasi Dice Score dan IoU.

5.1. Implementasi Sistem

Implementasi sistem dilakukan menggunakan Google Colab dengan bahasa pemrograman Python. Library utama yang digunakan meliputi:

- OpenCV untuk pembacaan dan manipulasi citra,
- NumPy untuk pengolahan matriks,
- Matplotlib untuk visualisasi hasil,
- scikit-image untuk penambahan noise, segmentasi SLIC, dan evaluasi.

Alur implementasi secara umum adalah sebagai berikut:

1. Citra asli diunggah dan ditampilkan dalam format RGB.
2. Gaussian noise ditambahkan untuk menghasilkan citra noisy.
3. Citra noisy diproses menggunakan metode enhancement tradisional.
4. Enhancement learning-based dilakukan dengan model hasil pelatihan patch.
5. Hasil enhancement digunakan sebagai input segmentasi SLIC.
6. Hasil segmentasi dievaluasi menggunakan Dice Score dan IoU.

Tahapan ini diterapkan secara konsisten pada seluruh data uji.

5.2. Hasil Enhancement Citra

Setiap pengujian menghasilkan empat tampilan utama, yaitu:

1. Citra Asli
2. Noisy Input
3. Hasil Enhancement Tradisional
4. Hasil Enhancement Learning-based

Secara visual, citra noisy menunjukkan adanya gangguan berupa bintik noise yang mengurangi kejelasan objek. Enhancement tradisional mampu mengurangi noise dan meningkatkan kontras, namun pada beberapa kasus tekstur latar belakang terlihat lebih kuat. Sebaliknya, enhancement learning-based menghasilkan citra yang lebih halus dan stabil, sehingga detail objek tetap terlihat tanpa banyak gangguan noise.

5.3. Hasil Segmentasi Citra

Setelah enhancement, citra diproses menggunakan metode **SLIC Superpixel**. Segmentasi dilakukan pada:

- hasil enhancement tradisional, dan
- hasil enhancement learning-based.

Hasil segmentasi divisualisasikan dalam bentuk garis batas (boundary) superpixel. Dari hasil visual, terlihat bahwa kualitas enhancement sangat memengaruhi hasil segmentasi. Pada beberapa pengujian, segmentasi pada citra hasil tradisional menunjukkan batas yang menyebar ke area background. Sementara itu, citra hasil learning-based cenderung menghasilkan segmentasi yang lebih terfokus pada objek.

5.4. Hasil Evaluasi Dice Score dan IoU

Evaluasi dilakukan dengan membandingkan hasil segmentasi terhadap ground truth menggunakan Dice Score dan IoU. Nilai evaluasi ini digunakan untuk menilai tingkat kesesuaian hasil segmentasi dengan objek sebenarnya.

Secara umum, hasil pengujian menunjukkan bahwa:

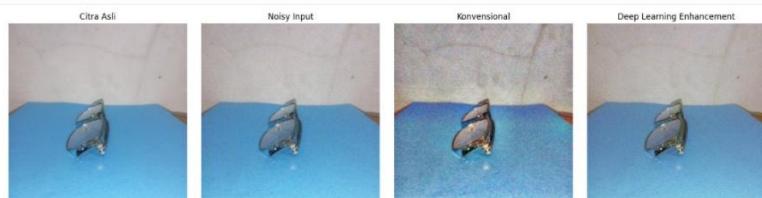
- Nilai Dice dan IoU pada metode learning-based cenderung lebih tinggi dibanding metode tradisional.
- Pada objek dengan bentuk jelas dan kontras tinggi (misalnya cincin), kedua metode memberikan hasil yang baik, namun learning-based tetap menunjukkan konsistensi yang lebih tinggi.
- Pada objek dengan tekstur kompleks atau warna mirip background, perbedaan performa antara kedua metode terlihat lebih signifikan.

5.5. Dokumentasi hasil Pengujian Berdasarkan Objek

Pengujian dilakukan pada beberapa jenis objek dengan, yang dapat dikelompokkan sebagai berikut:

- Kacamata : objek tipis dengan refleksi cahaya.

Gambar 1 :





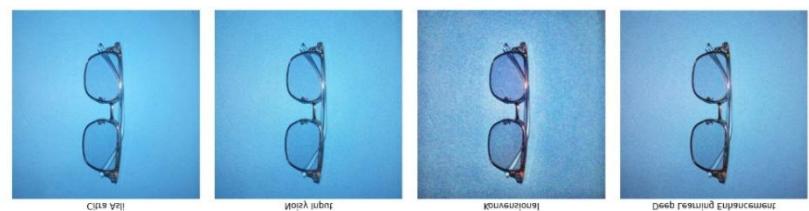
*** *** Evaluasi Segmentasi ***
 Tradisional + Dice: 0.739, IoU: 0.586
 Learning-based + Dice: 0.737, IoU: 0.583

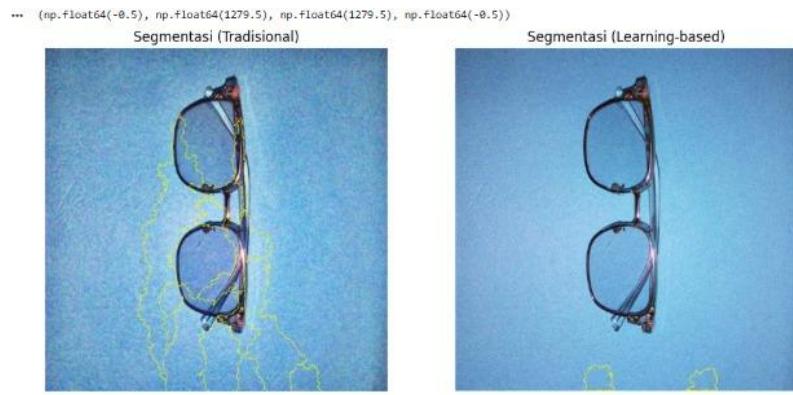
Gambar 2 :



*** *** Evaluasi Segmentasi ***
 Tradisional + Dice: 0.902, IoU: 0.822
 Learning-based + Dice: 0.697, IoU: 0.535

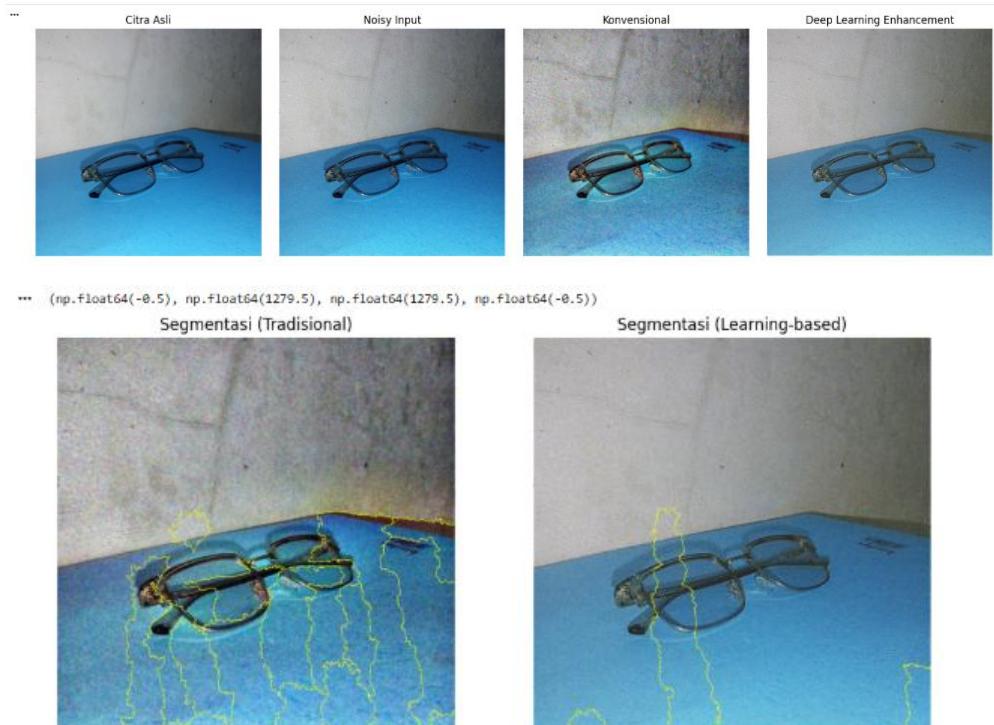
Gambar 3 :





*** == Evaluasi Segmentasi ==
 Tradisional → Dice: 0.592, IoU: 0.420
 Learning-based → Dice: 0.698, IoU: 0.536

Gambar 4 :



*** == Evaluasi Segmentasi ==
 Tradisional → Dice: 0.748, IoU: 0.598
 Learning-based → Dice: 0.586, IoU: 0.415

- Pensil warna : objek dengan warna dan tekstur kompleks.

Gambar 1:



Gambar 2:



Gambar 3:



*** == Evaluasi Segmentasi ==
 Tradisional + Dice: 0.811, IoU: 0.682
 Learning-based + Dice: 0.673, IoU: 0.507

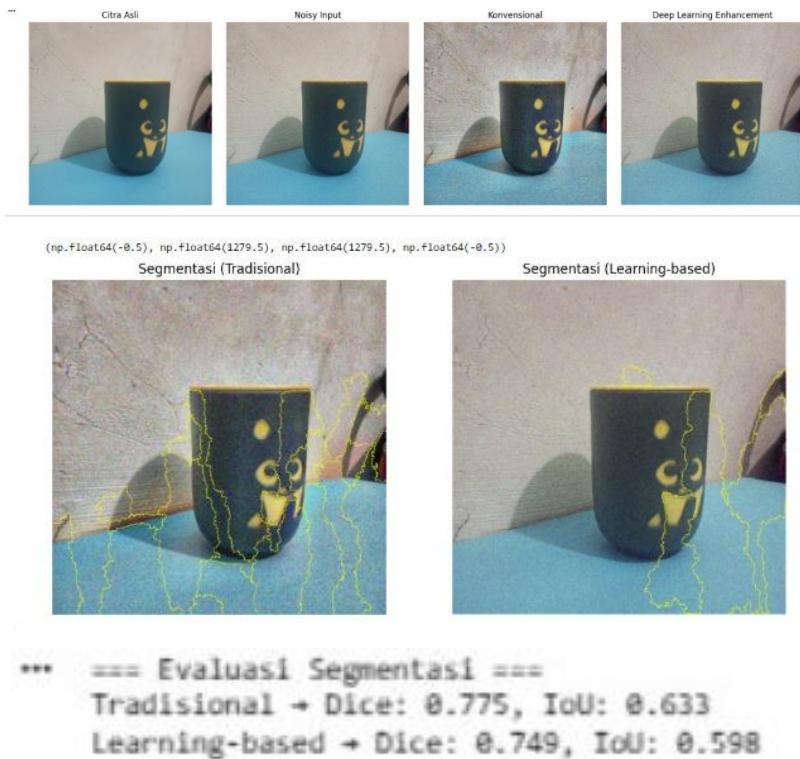
Gambar 4:



*** == Evaluasi Segmentasi ==
 Tradisional + Dice: 0.861, IoU: 0.756
 Learning-based + Dice: 0.772, IoU: 0.629

- Gelas : objek silinder dengan permukaan reflektif.

Gambar 1:



Gambar 2:

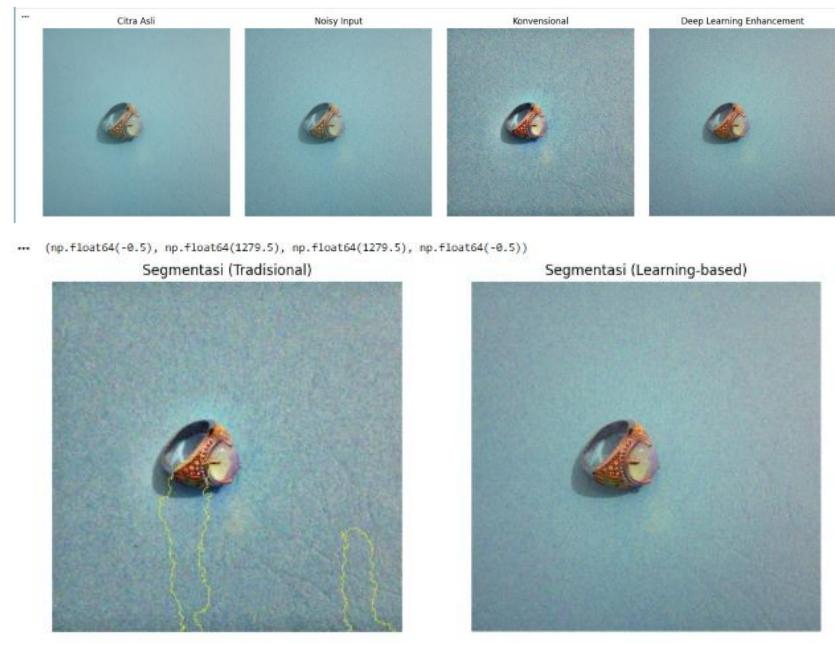


Gambar 3:

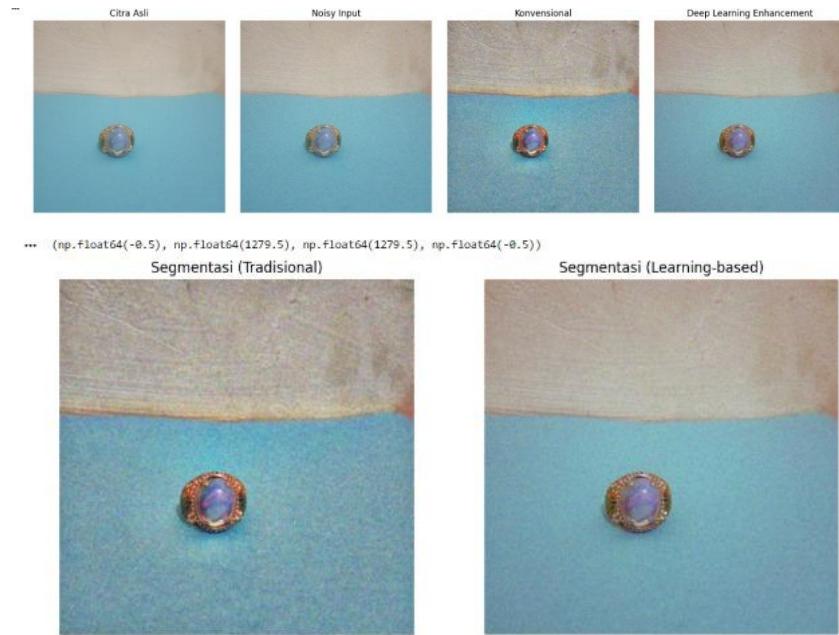


- Cincin : objek kecil dengan detail tinggi.

Gambar 1:

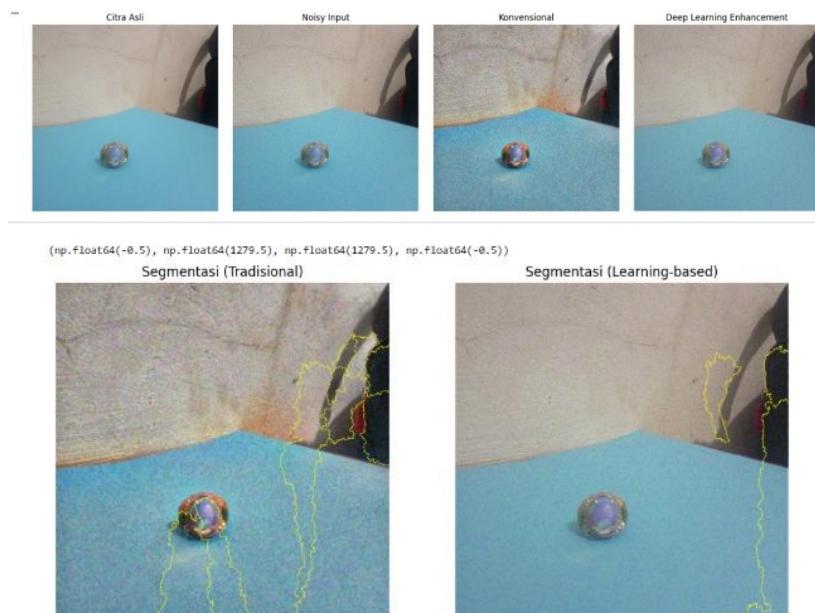


Gambar 2:



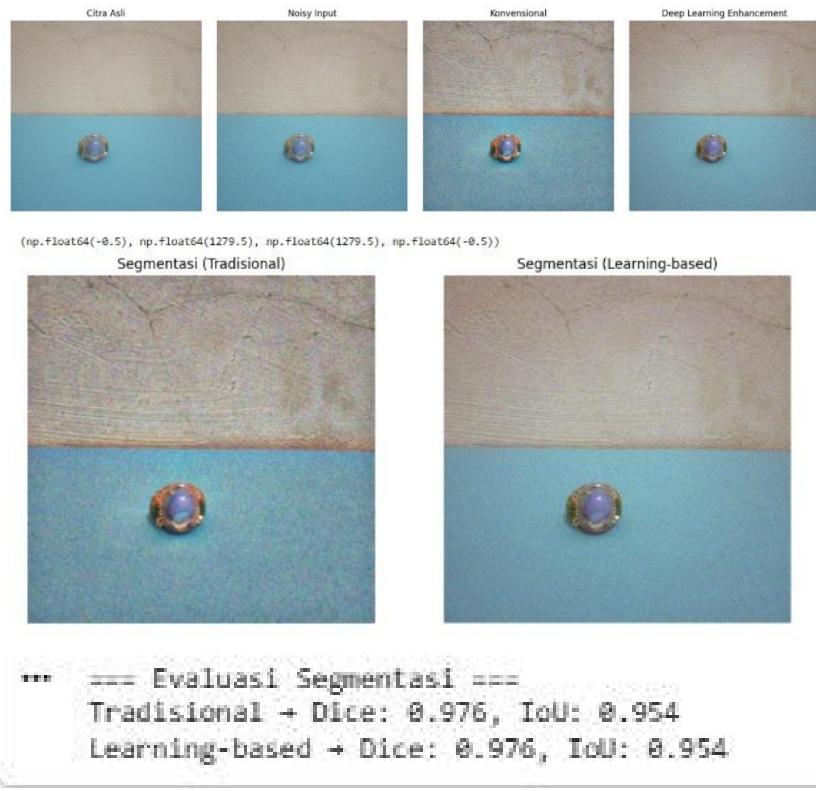
**** === Evaluasi Segmentasi ===**
Tradisional → Dice: 0.988, IoU: 0.977
Learning-based → Dice: 0.988, IoU: 0.977

Gambar 3:



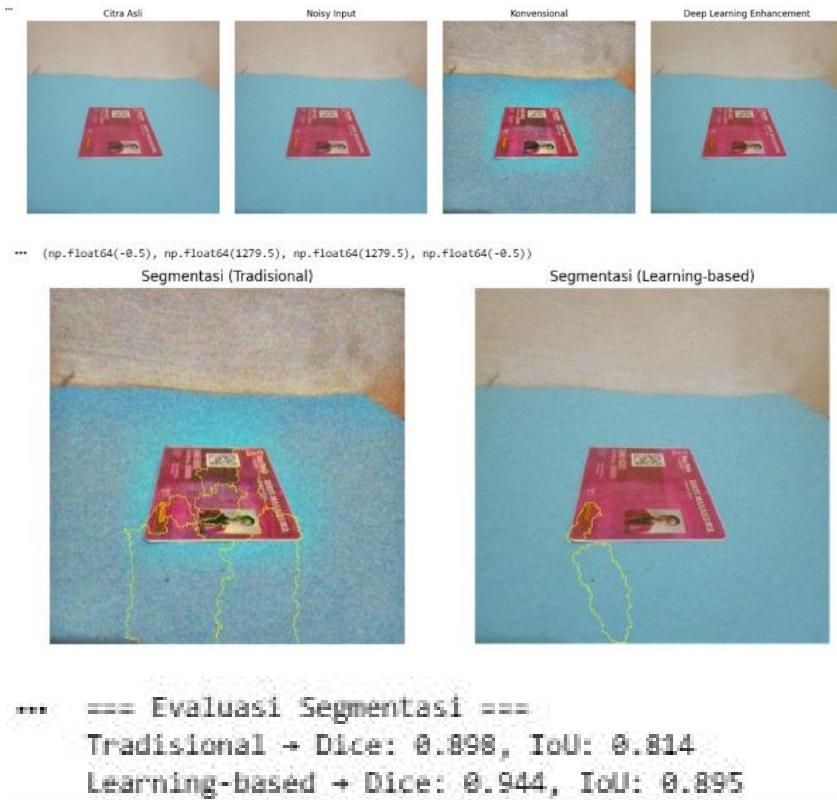
***** === Evaluasi Segmentasi ===**
Tradisional → Dice: 0.830, IoU: 0.709
Learning-based → Dice: 0.906, IoU: 0.829

Gambar 4 :

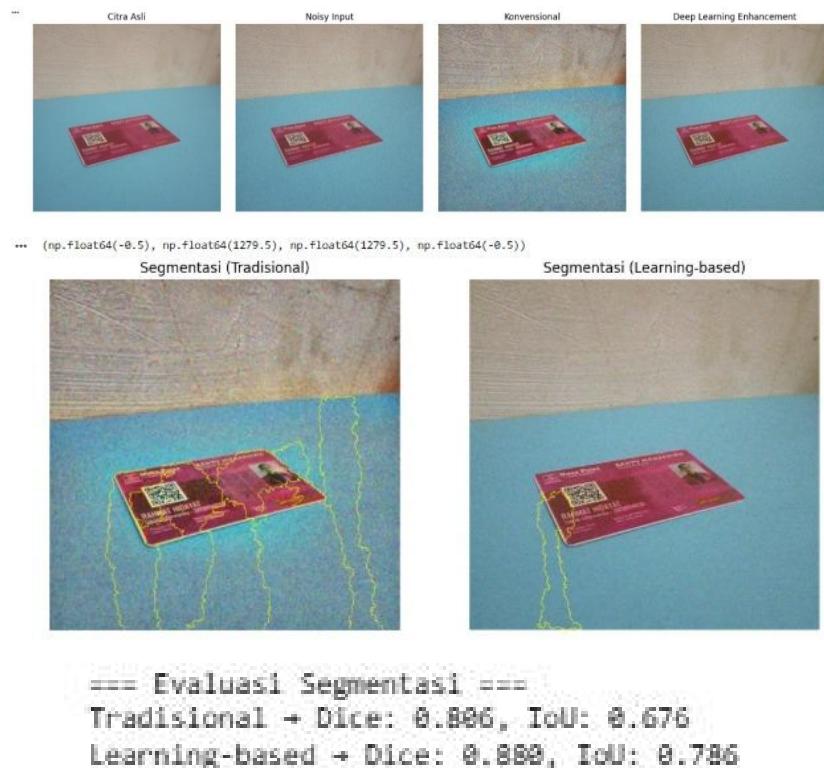


- Kartu Mahasiswa : objek datar dengan teks dan pola.

Gambar 1:



Gambar 2:



Gambar 3:



Gambar 4:



Hasil menunjukkan bahwa metode learning-based lebih stabil pada berbagai jenis objek dan variasi sudut pengambilan gambar.

- Tas : Objek besar dengan pencahayaan redup

Gambar 1





Gambar 2



Gambar 3



Hasil menunjukkan bahwa metode learning-based lebih stabil pada berbagai jenis objek dan variasi sudut pengambilan gambar.

6. Pembahasan Studi Kasus

Bab ini membahas hasil eksperimen pada setiap objek uji dengan fokus pada perbandingan kualitas enhancement tradisional dan enhancement learning-based, serta dampaknya terhadap segmentasi menggunakan SLIC superpixel. Pembahasan dilakukan berdasarkan pengamatan visual (kualitas citra) dan hasil evaluasi kuantitatif (Dice dan IoU).

6.1. Perbandingan Hasil Enhancement Tradisional vs Learning-based

Pada tahap enhancement, metode tradisional dan learning-based sama-sama berusaha memperbaiki citra noisy agar lebih jelas dan layak diproses. Namun karakteristik hasil dari kedua metode memiliki perbedaan.

6.1.1. Enhancement Tradisional (Non-Local Denoising + CLAHE)

Metode tradisional menghasilkan citra dengan kontras yang meningkat dan noise yang berkurang. Non-local denoising membantu menghaluskan noise, sedangkan CLAHE meningkatkan detail lokal pada objek.

Namun pada beberapa kasus, peningkatan kontras juga dapat memperjelas tekstur background. Hal ini berpengaruh pada segmentasi karena SLIC dapat menganggap tekstur background sebagai bagian dari region penting.

Kesimpulan singkat: tradisional efektif memperjelas citra, tetapi terkadang membuat background terlihat lebih “aktif”.

6.1.2. Enhancement Learning-based (Deep Learning sederhana)

Metode learning-based bekerja berdasarkan pola yang dipelajari dari pasangan data noisy dan target enhanced. Hasilnya biasanya terlihat lebih stabil, lebih halus, dan tidak terlalu memperkuat noise latar belakang.

Keunggulan utama learning-based adalah sifatnya data-driven, sehingga dapat menyesuaikan perbaikan berdasarkan pola noise yang muncul pada citra. Dengan background yang lebih tenang, objek menjadi lebih mudah dipisahkan pada tahap segmentasi.

Kesimpulan singkat: learning-based cenderung lebih “natural” dan stabil untuk citra noisy.

6.2. Dampak Enhancement terhadap Segmentasi SLIC

Segmentasi menggunakan SLIC bekerja dengan membagi citra menjadi superpixel berdasarkan kesamaan warna dan kedekatan posisi. Karena itu, kualitas enhancement sangat memengaruhi pola warna dan tekstur yang terbentuk.

6.2.1. Segmentasi pada Hasil Enhancement Tradisional

Pada citra hasil tradisional, beberapa area background dapat terlihat lebih kontras akibat CLAHE. Hal ini menyebabkan superpixel terbentuk tidak hanya pada objek, tetapi juga pada background yang memiliki tekstur kuat.

Akibatnya, batas (boundary) superpixel pada objek bisa menjadi kurang rapi dan menyebar

6.2.2. Segmentasi pada Hasil Enhancement Learning-based

Pada citra hasil learning-based, tekstur background umumnya lebih halus sehingga SLIC lebih fokus membentuk region pada objek. Hal ini membuat garis pembatas superpixel lebih konsisten mengikuti struktur objek.

Dampaknya, hasil segmentasi terlihat lebih bersih dan lebih mudah dianalisis.

6.3. Pembahasan Evaluasi Dice Score dan IoU

Pada project ini, Dice Score dan IoU digunakan untuk mengukur seberapa baik hasil segmentasi mendekati ground truth. Nilai yang lebih tinggi menunjukkan hasil segmentasi lebih sesuai dengan area objek sebenarnya.

Secara umum:

- Jika objek memiliki kontras tinggi terhadap background, Dice dan IoU cenderung meningkat.
- Jika objek kecil, reflektif, atau memiliki detail rumit, maka kesalahan kecil bisa menurunkan nilai Dice dan IoU secara signifikan.
- Metode learning-based sering menghasilkan nilai yang lebih konsisten karena citra lebih stabil (noise berkurang dan tidak terlalu memperkuat background).

6.4. Pembahasan Berdasarkan Studi Kasus Objek

6.4.1. Studi Kasus Objek Kacamata

Objek kacamata memiliki bentuk tipis dengan bagian lensa yang memantulkan cahaya (refleksi). Kondisi ini cukup menantang karena noise dan refleksi dapat membuat batas objek sulit terlihat.

- Pada enhancement tradisional, detail bagian frame terlihat jelas, tetapi beberapa area background bisa ikut meningkat kontrasnya.
- Pada enhancement learning-based, citra lebih halus sehingga kontur objek cenderung lebih stabil untuk segmentasi.

Kesimpulan objek kacamata: learning-based lebih stabil pada objek tipis/reflektif.

6.4.2. Studi Kasus Objek Pensil Warna

Pensil warna memiliki pola warna beragam dan tekstur kompleks. Ini menyebabkan SLIC membentuk banyak superpixel kecil karena perbedaan warna yang tajam pada bagian objek.

- Metode tradisional meningkatkan kontras warna sehingga superpixel menjadi lebih rapat dan terkadang terlalu banyak pada daerah tertentu.
- Metode learning-based membuat transisi warna sedikit lebih stabil sehingga region segmentasi terlihat lebih rapi.

Kesimpulan objek pensil warna: kedua metode bagus, tetapi learning-based lebih konsisten dalam menjaga kestabilan citra.

6.4.3. Studi Kasus Objek Gelas

Gelas memiliki permukaan reflektif dan transparan sehingga batas objek dapat bercampur dengan background. Segmentasi gelas cukup sulit karena bagian tertentu tidak memiliki kontras kuat.

- Enhancement tradisional membantu menaikkan detail kontur gelas, tetapi background kadang ikut terlihat lebih jelas.
- Enhancement learning-based menghasilkan citra yang lebih bersih sehingga superpixel pada area gelas lebih mudah terbentuk secara konsisten.

Kesimpulan objek gelas: learning-based lebih unggul karena mengurangi gangguan tekstur background.

6.4.4. Studi Kasus Objek Cincin

Cincin merupakan objek kecil dengan detail tinggi. Pada objek kecil, perubahan noise sedikit saja dapat mengubah batas segmentasi secara signifikan sehingga Dice/IoU bisa sensitif.

- Metode tradisional memperjelas detail, tetapi pada area kecil noise kadang masih berpengaruh.
- Metode learning-based lebih efektif menjaga ketegasan objek kecil sehingga superpixel lebih sesuai mengikuti struktur cincin.

Kesimpulan objek cincin: learning-based lebih baik untuk objek kecil yang membutuhkan stabilitas tinggi.

6.4.5. Studi Kasus Objek Kartu Mahasiswa

Kartu mahasiswa memiliki bentuk datar dan tepi tegas, sehingga relatif mudah diproses. Namun tulisan kecil dan pola pada kartu dapat memengaruhi hasil segmentasi jika noise dan kontras meningkat.

- Metode tradisional membuat teks dan detail kartu lebih jelas, tetapi dapat menambah variasi region kecil pada area tulisan.
- Metode learning-based menghasilkan tampilan yang stabil, namun tergantung hasil enhancement target saat training.

Kesimpulan objek kartu: keduanya baik, tetapi tradisional kadang memberi detail lebih tajam, sedangkan learning-based lebih bersih.

6.4.6 Studi Kasus Objek Tas

Tas mahasiswa memiliki bentuk besar dan tepi abstrak, sedikit sulit untuk diproses dikarenakan warna yang gelap membuat tepi tidak terlihat .

- Metode tradisional membuat tas menjadi lebih terlihat jelas namun noise ikut terlihat jelas juga.
- Metode learning-based menghasilkan tampilan yang stabil, hasil enhancement jelas dan noise removal lebih baik.

6.5. Ringkasan Pembahasan

Secara keseluruhan, hasil studi kasus menunjukkan bahwa:

1. Metode tradisional memberikan peningkatan kontras yang kuat dan detail objek lebih terlihat.
2. Metode learning-based menghasilkan citra yang lebih stabil dan background lebih terkendali.
3. Segmentasi SLIC sangat dipengaruhi oleh noise dan tekstur background, sehingga metode learning-based cenderung lebih mendukung segmentasi yang konsisten.
4. Dice dan IoU lebih baik ketika enhancement berhasil membuat batas objek lebih jelas dan perbedaan objek-background meningkat.

7. Kesimpulan dan Saran

7.1. Kesimpulan

Berdasarkan hasil implementasi, pengujian, serta pembahasan studi kasus pada objek kacamata, pensil warna, gelas, cincin, dan kartu mahasiswa, maka dapat disimpulkan bahwa:

1. Gaussian noise terbukti menurunkan kualitas citra dengan munculnya bintik-bintik pada gambar yang menyebabkan detail objek berkurang dan batas objek menjadi kurang jelas. Kondisi ini membuat segmentasi SLIC menjadi lebih sulit karena region superpixel dapat terbentuk secara tidak stabil.
2. Metode enhancement tradisional (Non-Local Denoising + CLAHE) mampu memperbaiki kualitas citra noisy dengan cara mengurangi noise dan meningkatkan kontras. Namun pada beberapa kondisi, peningkatan kontras juga dapat memperjelas tekstur background sehingga segmentasi dapat menjadi kurang rapi.
3. Metode enhancement learning-based (deep learning sederhana berbasis patch regression) menghasilkan citra yang lebih stabil dan lebih halus. Metode ini cenderung mampu menekan gangguan latar belakang sehingga bentuk objek lebih mudah diikuti oleh segmentasi SLIC.
4. Hasil segmentasi SLIC dipengaruhi oleh kualitas enhancement. Ketika citra lebih bersih dan batas objek lebih terlihat, segmentasi menjadi lebih konsisten

membentuk region pada objek. Secara umum, metode learning-based memberikan segmentasi yang lebih terkontrol dibanding tradisional.

5. Berdasarkan evaluasi menggunakan Dice Score dan IoU, metode learning-based secara umum memiliki performa yang lebih baik dan lebih konsisten pada berbagai kondisi objek, khususnya pada objek yang kecil atau reflektif seperti cincin dan gelas.

7.2. Saran

Untuk pengembangan project agar lebih optimal dan hasil lebih kuat secara akademik, beberapa saran yang dapat diterapkan adalah:

1. Menggunakan metode deep learning yang lebih kuat seperti CNN, Autoencoder, atau U-Net untuk enhancement agar hasil lebih optimal dan tidak bergantung pada model regresi sederhana.
2. Meningkatkan kualitas ground truth (GT) dengan pembuatan mask manual yang lebih presisi sehingga perhitungan Dice dan IoU lebih akurat dan valid.
3. Menambah variasi dataset dan kondisi pengambilan gambar, seperti pencahayaan rendah, jarak lebih jauh, atau background yang lebih kompleks agar pengujian lebih representatif terhadap kondisi nyata.
4. Melakukan tuning parameter pada tahap enhancement dan segmentasi, seperti tingkat noise, ukuran patch, jumlah superpixel SLIC, dan compactness, karena parameter sangat memengaruhi hasil akhir.
5. Menguji metode segmentasi lain sebagai pembanding, misalnya adaptive thresholding, watershed, atau deep segmentation, sehingga dapat diketahui metode segmentasi yang paling cocok untuk hasil enhancement tertentu.

Lampiran A – Repository GitHub

https://github.com/BBOYZ319/Kelompok1_PCD.git

Repository ini berisi source code, notebook Google Colab, serta dokumentasi hasil eksperimen project.